Обучаемые признаки в рекомендательном ранжировании

CatBoost, EASE и контрастивные связи: архитектура и контролируемое сравнение

KION / Yambda / Эмпирическое исследование, октябрь 2026

Аннотация. Можно ли получить полезные признаки из истории автоматически и уменьшить зависимость рекомендаций от ручных агрегатов? Сравниваем ручной CatBoost, гибриды с EASE и контрастивной моделью, а затем самостоятельное ранжирование по обученным связям. В KION EASE-признаки дали прирост к manual $\Delta\text{NDCG@10} = +0.00860$; превосходство над популярностью не установлено. На Yambda условная перестановка продолжений внутри user–day не улучшила гибрид с CatBoost: -0.00075, 95% CI $[-0.00197; +0.00037]$. Факторная проверка на другой когорте отделяет способ объединения истории от восстановления фоновой массы. Основная совместная реконструкция ухудшила NDCG на -0.02471; вторичное арифметическое объединение улучшило свой standalone baseline, но осталось слабее ручного CatBoost. Показываем устройство пайплайна, интерпретацию этих эффектов и ограничения переноса.

1 Исследовательский вопрос

В ручном признаке инженер задаёт отношение между сущностями, статистику и масштаб времени. Обученное представление может снять часть этой работы, но его учебная цель обычно отличается от цели ранжирования. Низкий loss различения реальных и шумовых переходов сам по себе не обосновывает полезность полученного score для рекомендаций.

Проверяем три вопроса: добавляют ли обученные связи информацию сверх ручных агрегатов; сохраняет ли условный фон полезный персональный сигнал; что меняется при переходе от среднего вектора к смеси исторических экспертов. Вклад работы состоит в перестановочной конструкции внутри user–day, разборе её поддержки и факторной проверке двух способов преобразования score. Известные принципы обучения отношения вероятностей и смешивания распределений не объявляются новыми.

Связь с литературой. EASE [1] учит линейные item–item отношения по разреженной матрице взаимодействий. NCE [2] и анализ negative sampling [3] связывают различение данных и шума с отношением распределений. Произведение и смесь экспертов [4] по-разному объединяют свидетельства. Здесь эти принципы проверяются совместно в одном временном протоколе, а не предлагаются как новые общие алгоритмы.

2 Архитектура решения

Пайплайн разделяет отбор кандидатов, извлечение признаков и ранжирование (рис. 1). Для момента t из доступной истории формируется общий список C_{ut}. Две ветви вычисляют признаки одной и той же пары (u, j): ручная ветвь задаёт агрегаты x_{uj}, обучаемая строит связи между объектами и персональные scores ϕ_{uj}. Ручной CatBoost получает x; гибрид — конкатенацию $[x, \phi]$. Ранжировщик обучается на прошлых размеченных срезах, а не на test-метках.

EASE в KION и NCE в Yambda — альтернативы, не последовательные слои. EASE учит матрицу item–item связей. NCE учит две таблицы embeddings для начала и продолжения перехода. При прогнозе модель читает уже наблюдённую историю пользователя и оценивает кандидата через эти связи. Обучение представления и обучение CatBoost являются отдельными этапами.

Таблица 1. Популяции итоговых сравнений. A/B не пересекаются по UID, но относятся к одному периоду и могут иметь общие объекты.

Выборка	Взято	Оценено	Событий
KION	10 000	834	—
Yambda A	1 000	620	4.86 млн
Yambda B	1 000	636	5.20 млн

На Yambda дополнительно убираем ручной ранжировщик и проверяем четыре способа объединения тех же экспертов истории: G_0, G_1, A_0, A_1. Этот контроль отвечает на вопрос о преобразовании score; его прирост не считается автоматически улучшением полного гибрида. Все маршруты сохраняют общие кандидаты и правила учёта пропущенных целей.

3 Экспериментальная постановка

Цель и популяция. В KION [5] ранжируем новые для пользователя объекты следующей недели. В Yambda [6] цель $R_{u,t}$ — уникальные треки следующих суток с долей прослушивания $\geq 50\%$, включая повторы. Используем `listens` варианта `flat/50m`. Выбираем UID равномерно, затем сохраняем все их исходные строки. Выборка не зависит от будущей активности; оценка условна на наличии прошлого и хотя бы одной будущей цели.

Время и выбор настроек. Для Yambda история удовлетворяет $t_e < t - 1800$; горизонт метки — сутки. Обучающие срезы: 286/288/290/292, выбор настроек: 294, проверочный срез: 296, тест: 298/299. Перед тестом бустинг переобучается на шести прошлых срезах с уже выбранными параметрами; его метки заканчиваются до дня 297. На втором тестовом дне история обновляется, бустинг не дообучается. Все прогнозы обоих дней сохранены до построения их целей.

Когорта B зарезервирована до нового поиска вне всех UID когорты A. Её модели обучены с нуля по её прошлому; параметры перенесены с A. Это перенос на других

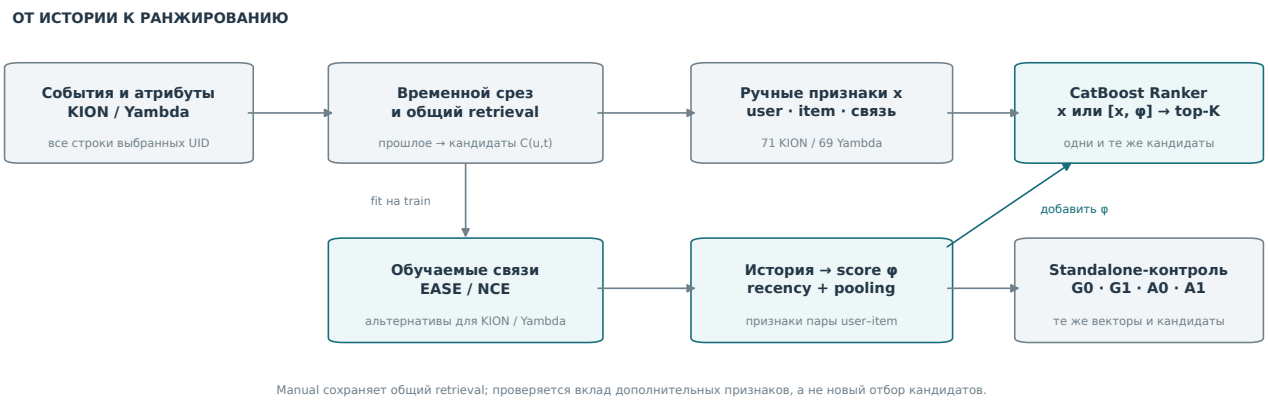


Рис. 1. Архитектура исследования. Ручные и обучаемые признаки вычисляются на общем списке кандидатов; EASE/NCE обозначают альтернативные модели для разных данных. Standalone-контроль отделён от гибрида. Manual сохраняет retrieval scores и номинации обученных моделей, поэтому сравнение измеряет вклад добавочных признаков, а не удаление всей обученной информации.

пользователей того же периода. Проверка KION на 21–27 июня 2021 ретроспективна: настройки выбраны на августовском development, затем перенесены на новые UID и июньские метки.

Кандидаты и метрики. Внутри сравнения у методов один набор $C_{u,t}$ из прошлой истории: до 240 кандидатов в KION и до 300 в Yambda. Будущие положительные объекты не добавляются. В Recall и идеальном DCG используется полное $R_{u,t}$, включая cold и не извлечённые цели. Это оценка всей цепочки отбора и ранжирования; случайное сокращение каталога меняло бы саму метрику [7].

Основная метрика — NDCG@10. Сначала усредняем метрики трёх seed внутри user–day, затем доступные дни пользователя, затем пользователей. Парный percentile bootstrap из 3000 выборок пересэмплирует UID целиком. Интервалы условны на текущих моделях и фиксированном отборе кандидатов; переобучение и вариативность других периодов в них не входят.

4 Модели и контролируемые изменения

4.1 Бейзлайны и обучаемые признаки

Простые контроли — популярность, UserKNN и, в Yambda, частоты недавних повторов. CatBoostRanker обучается с YetiRank NDCG@10, шагом 0.05 и L2=5. Ручной набор содержит 71 признак в KION и 69 в Yambda: частоты, давность, доли, связи с категориями/исполнителями, окна 1/7/30 дней, вся история и оценки отбора кандидатов. Поиск дополнительных окон на двух KION-выборках по 10 тысяч UID не дал устойчивого выигрыша. Для EASE добавляем шесть оценок: две регуляризации и три временных профиля.

В Yambda одинаковые 64-мерные векторы начала и продолжения обучаются 15 эпох на соседних положительных прослушиваниях с лагом $(0, 30$ мин$]$ за последние 30 дней (SparseAdam, шаг 0.01, batch 8192). Каждому переходу соответствует один шумовой пример. Глобальный и условный варианты имеют одинаковые начальные веса, порядок пакетов положительных примеров и бюджет бустинга: глубины 5/7, до 600 деревьев, проверка каждые 25 деревьев. Три оценки добавляются к одному ручному набору. Отбор кандидатов общий, поэтому ручной метод косвенно использует номинации обученных моделей через общий RRF/rank.

4.2 Какой сигнал оставляет фон

При глобальной перестановке продолжений в ожидании $q_g(i,j) = p_s(i)p_t(j)$. При перестановке внутри $z = (u, \text{day})$ получаем другой совместный фон:

$$q_c(i,j) = \frac{1}{N}\sum_z \frac{a_{zi}b_{zj}}{n_z}, \tag{1}$$

где a, b — частоты начал и продолжений, n_z — число переходов в страте, $N = \sum_z n_z$. Для каждой source-позиции вероятность получить j равна b_{zj}/n_z; линейности ожидания достаточно для (1). Обе перестановки сохраняют глобальные частоты обоих концов переходов. Различие касается совместных связей и сохранения пользовательского состава. Условный фон способен вычесть предпочтения, полезные для рекомендаций.

Для сбалансированного logistic loss неограниченный оптимум при $p, q > 0$ равен $f^* = \log(p/q)$. Наша билинейная модель $f_\theta(i,j) = a_i^\top b_j/\sqrt{64}$ ограничена по рангу; формула оптимума — интерпретация, а не гарантия её обучения. При $p = q_c = 0$ loss пары отсутствует, и её score не идентифицируется данными. Смесь $q_m = (q_g + q_c)/2 \geq q_g/2$ даёт положительную массу всем парам известных начал и продолжений; отдельный эксперимент проверяет, достаточно ли этого для качества.

4.3 От среднего вектора к факторной проверке

Для нормированных весов истории билинейность даёт

$$\sum_i w_{ui} f^*(i,j) = \log \frac{\prod_i p(j \mid i)^{w_{ui}}}{p_t(j)}. \tag{2}$$

Средний вектор геометрически объединяет отношения вероятностей. Такое объединение требует согласия частей истории; арифметическая смесь допускает несколько режимов интереса. Например, для экспертов $(.80, .19, .01)$ и $(.01, .19, .80)$ с равными весами геометри-

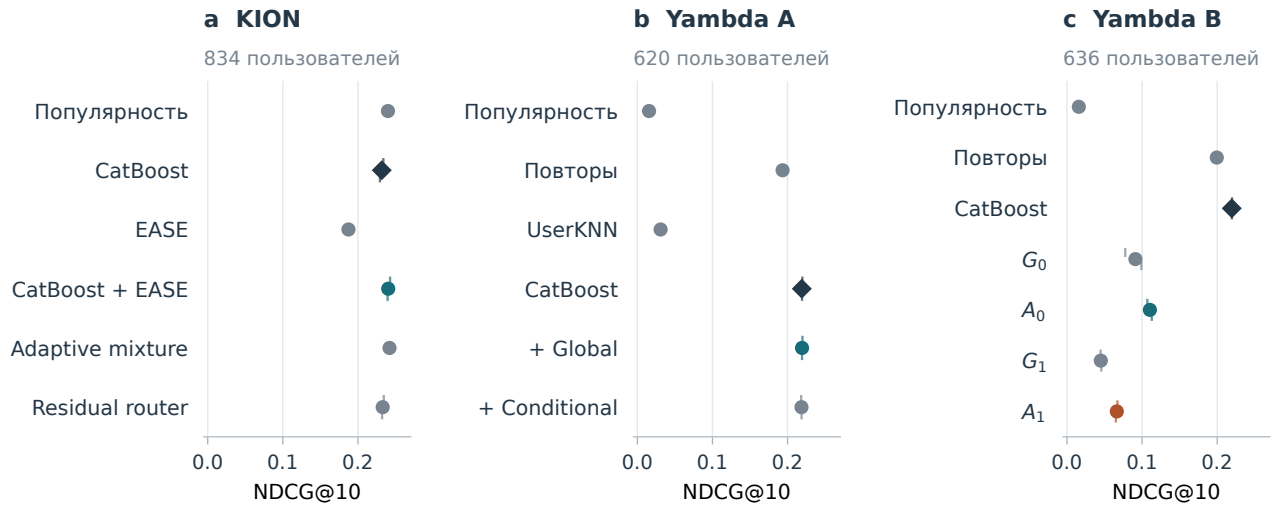


Рис. 2. Абсолютное качество и сильные контроли на трёх выборках. Крупные точки — user-macro средние; малые вертикальные отметки — метрики трёх pipeline seed, где есть три отдельных fit. Это не доверительные интервалы. Ромб обозначает ручной CatBoost. В KION adaptive mixture имеет лучшую тестовую точку, но не был выбран на search. Абсолютные метрики разных панелей относятся к разным задачам и не сравниваются напрямую.

ческое правило выбирает средний объект, смесь — крайний. Если цель выбирается из смеси экспертов, ожидаемый Hit@1 равен .19 и .405. Это конструктивное расхождение решений, не измеренный online-эффект.

На когорте B фиксируем одни векторы и меняем только два фактора: добавить ли историческую массу $q(j)$ и как объединить экспертов:

$$r_i^{(b)}(j) = \mathrm{softmax}_{j \in C_u}[f(i,j) + b \log q(j)],$$
$$G_b(j) = \sum_i w_{ui} \log r_i^{(b)}(j),$$
$$A_b(j) = \log \sum_i w_{ui} r_i^{(b)}(j), \quad b \in \{0,1\}. \tag{3}$$

Профиль — последние 100 положительных событий, полупериод 24 часа. Маски обученных ролей, нижняя граница 10^{-12} и правило пустой истории одинаковы. Неподдержанные кандидаты не удаляются из оценки. Нормировка по C_u даёт смесь условных на кандидатах экспертов; она не восстанавливает автоматически полную вероятность следующего дня. *Основное заранее заданное сравнение* — $A_1 - G_0$; остальные факторные контрасты описательные.

5 Результаты и интерпретация

5.1 Обученные признаки поверх CatBoost

На KION гибрид EASE улучшил замороженный ручной CatBoost с 0.23173 до 0.24033 ($\Delta = +0.00860$). Популярность дала 0.24000; интервал разности hybrid–popularity $[-0.00491; +0.00545]$ включает ноль. Имеется улучшение конкретного GBDT, но не доказательство превосходства над сильнейшим доступным контролем. Собственный residual router также не дал убедительного выигрыша; все варианты видны на рис. 2.

На Yambda A условный фон уступил глобальному на -0.00075; интервал включает ноль. Global–manual равен +0.00035 с интервалом $[-0.00073; +0.00151]$: добавочная польза не установлена. Raw/signed графы не дают прироста. Исправление поддержки смесью noise тоже не улучшило manual (-0.00096; $[-0.00301; +0.00101]$). По search выбран ручной вариант; лидер тестовой точки не становится выбранной моделью задним числом.

5.2 Раздельные эффекты фона и агрегации

Основное $A_1 - G_0$ на новой когорте отрицательно: -0.02471 с интервалом $[-0.03280; -0.01652]$. Это совместное изменение двух компонентов. Их разложение на рис. 3 показывает противоположные эффекты: арифметическое объединение улучшает самостоятельную оценку при обоих фонах, а добавление $\log q$ ухудшает оба правила объединения. Взаимодействие эффектов равно +0.00200 с интервалом $[-0.00372; +0.00802]$ и не получило подтверждения.

Вторичное $A_0 - G_0 = +0.01932$ не заменяет основную гипотезу. $A_0 = 0.11043$ остаётся значительно ниже manual (0.21944) и повторов (0.19948). Из 20 вариантов добавления этих оценок к ручному прогнозу на прежней валидации лучшим оказался нулевой вес. Таким образом, улучшение одного преобразования представления не стало улучшением полного ранжировщика.

5.3 Диагностика границ переноса

На старом search 93.4% глобально шумовых пар имеют нулевую массу условного фона; 92.6% различных наблюдаемых рёбер встретились один раз. Учебный AUC global/conditional равен .975/.950, на более поздних переходах — .648/.562. Последняя оценка использует 7890 положительных пар с известными обеими ролями, 74.8% всех поздних переходов; лишь 16.2% этих рёбер уже встречались. Это механистическая диагностика на когорте A, не новая подтверждающая проверка. Разрыв смешивает временной сдвиг и смену состава рёбер; его нельзя целиком приписать запоминанию.

Аудит после просмотра теста показал: более 54% кандидатов A новы для пользователя, но среднее покрытие

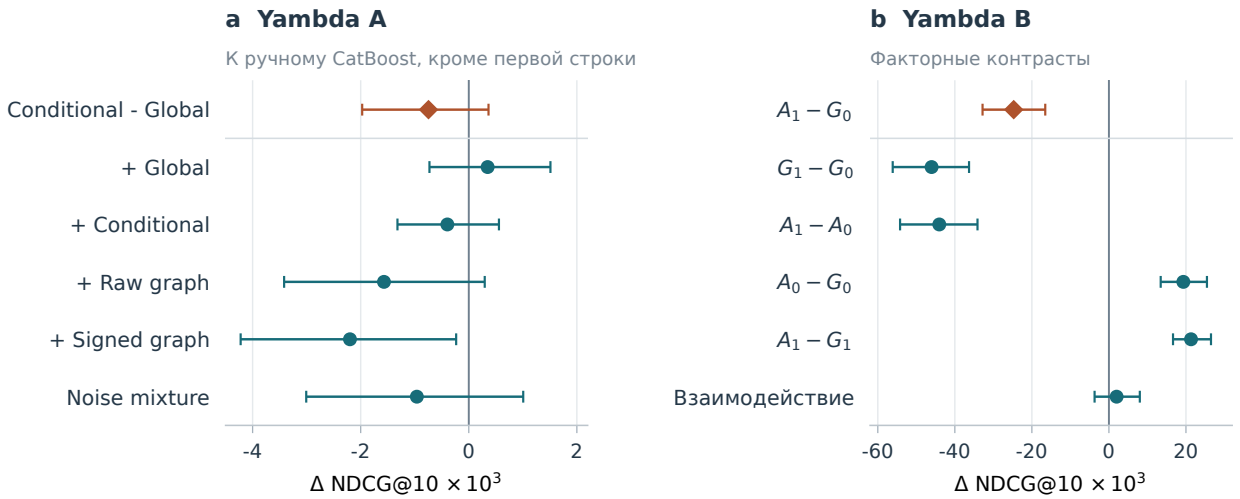


Рис. 3. Парные разности NDCG@10 и 95% user-cluster интервалы. Оранжевым выделены заранее основные гипотезы; остальные интервалы описательные, без поправки на множественные сравнения. Слева первая строка сравнивает conditional и global, остальные — с ручным CatBoost. Справа G/A и b определены в (3); взаимодействие равно $(A_1 - A_0) - (G_1 - G_0)$. Масштабы осей различаются; единица на каждой оси соответствует 10^{-3} NDCG.

Таблица 2. Три основные гипотезы, зафиксированные до соответствующих внешних метрик. Парные 95% интервалы относятся к пользователям, а не к распределению новых обучений.

Выборка	Сравнение	Пользователей	Δ NDCG@10	95% интервал
KION	CatBoost + EASE – manual	834	+0.00860	$[+0.00584; +0.01188]$
Yambda A	Conditional – Global	620	-0.00075	$[-0.00197; +0.00037]$
Yambda B	$A_1 - G_0$	636	-0.02471	$[-0.03280; -0.01652]$

Таблица 3. Одинаковые векторы, история и кандидаты; меняются только два фактора. В ячейках NDCG@10 когорты B.

Объединение	$b = 0$	$b = 1$
Геометрическое G	0.09111	0.04507
Арифметическое A	0.11043	0.06639

релевантных новинок лишь 6.5–7.1%. Доля новинок в top-10 ручного бустинга около 0.05%, попаданий по ним нет. Общий NDCG здесь прежде всего характеризует повторное потребление. Этот аудит не менял опубликованные модели и кандидаты.

6 Ограничения и вывод

Новые UID не заменяют новый период: A/B имеют общий сервис, дни и часть items. Два дня и 1000 пользователей на когорту ограничивают внешний вывод. KION хранит последнюю дату пары, а не поток повторов; накопленные длительности и проценты просмотра исключены. Статические метаданные и задержки логирования остаются допущениями. Отсутствующее взаимодействие не является отказом после показа; CTR, причинный эффект и online-прирост не измеряются.

Средний вектор требует $O((L + K)d)$ операций на пользователя, явная смесь — $O(LKd)$ при $L \leq 100$, $K \leq 300$, $d = 64$. Полный перебор всё ещё зависит от размера каталога; теста промышленной скорости нет. В Yambda выполнены 120 обучений кодировщиков и 40 обучений CatBoost, включая поиск и когорту B. Все журналы, 66 replay-прогнозов B, замены будущих событий и пользовательские метрики доступны в репозитории. Проверка чисел не требует исходных данных или GPU.

Главный вывод: полезность contrastive-признака определяется не только качеством proxy-loss. Фон задаёт, какую ассоциацию вычитает модель, а объединение истории — как свидетельства преобразуются в ranking score. В выполненном протоколе их раздельное изменение имеет измеримые эффекты, но не заменяет сильные ручные признаки. Тесты открыты; дальнейший выбор настроек требует новой внешней проверки.

Список литературы

[1] H. Steck. Embarrassingly Shallow Autoencoders for Sparse Data. WWW, 2019. arXiv:1905.03375.

[2] M. Gutmann, A. Hyvärinen. Noise-contrastive estimation: A new estimation principle for unnormalized statistical models. AISTATS, 2010. PMLR 9:297–304.

[3] O. Levy, Y. Goldberg. Neural Word Embedding as Implicit Matrix Factorization. NeurIPS, 2014. Текст статьи.

[4] G. E. Hinton. Training Products of Experts by Minimizing Contrastive Divergence. Neural Computation 14:1771–1800, 2002. Текст статьи.

[5] A. Petrov et al. MTS Kion Implicit Contextualised Sequential Dataset for Movie Recommendation. 2022. arXiv:2209.00325.

[6] A. Ploshkin et al. Yambda-5B: A Large-Scale Multi-modal Dataset for Ranking And Retrieval. 2025. arXiv:2505.22238.

[7] W. Krichene, S. Rendle. On Sampled Metrics for Item Recommendation. KDD, 2020. Текст статьи.